MEMORIAL METODOLÓGICO & ALGORÍTMICO | CATÁLOGO MESTRE DE 28 MÉTRICAS | AUDITORIA REPRODUTÍVEL

Relatório Completo de Ferramentas, Métodos e Construção de Métricas

Especificação matemática, engenharia de dados, parametrização estatística e algoritmos de aprendizado de máquina aplicados ao estudo sobre Redes de Monitoramento, Avaliação (M&A) e Políticas Informadas por Evidências (PIE) no Brasil (2024)

MOTOR DE PROCESSAMENTO	BIBLIOTECAS CIENTÍFICAS	VOLUME DE DADOS BRUTOS	SEMENTE DETERMINÍSTICA
Python 3.12.x (64-bit)	**pandas, scipy, prince, sklearn**	**1.649 Registros (3 Bases .xlsx)**	**random_state = 42 (Fixada)**

1. Introdução e Arquitetura do Pipeline Científico

Este documento constitui o **Memorial Metodológico e Dicionário de Engenharia de Métricas** do estudo sobre a comunidade de Monitoramento e Avaliação (M&A) e Políticas Públicas Informadas por Evidências (PIE) no Brasil. Seu objetivo é documentar com transparência científica absoluta: **(i)** quais ferramentas e bibliotecas computacionais foram empregadas; **(ii)** como os dados brutos das três planilhas originais foram limpos, padronizados e transformados; **(iii)** as equações matemáticas exatas de todas as **28 métricas e indicadores** gerados; e **(iv)** os critérios estatísticos de validação dos modelos multivariados (Pareamento Determinístico, Teoria dos Conjuntos, Testes Qui-Quadrado, Análise de Correspondência Múltipla e Clusterização K-Means++).

Camada 1: Ingestão e Saneamento

Leitura nativa via `openpyxl`, decomposição Unicode `NFKD` para remoção de acentos, saneamento de CPFs (`zfill(11)`), tratamento de anomalias temporais e winsorização de *outliers*.

Camada 2: Modelagem Estatística

Record Linkage determinístico em 3 chaves, álgebra de conjuntos, tabelas de contingência (χ^2 e V de Cramér), decomposição SVD em Matriz de Burt (ACM) e K-Means++ padronizado (Z-Score).

Camada 3: Compilação Editorial

Serialização intermediária em JSON (`analise_dados_completa.json`) alimentando gráficos Matplotlib (300 DPI), relatórios PDF via Playwright Chromium, Excel de 9 abas, PPTX e Dashboard Web.

2. Ecossistema Tecnológico e Ferramentas Utilizadas

Cada etapa do trabalho utilizou ferramentas específicas selecionadas pela precisão numérica, reprodutibilidade por código-fonte (*Infrastructure as Code* para análise de dados) e ausência de edição manual humana sobre tabelas intermediárias:

FERRAMENTA / PACOTE	MÓDULO / CLASSE	APLICAÇÃO EXATA NA ANÁLISE DOS DADOS	PARÂMETROS E ESPECIFICAÇÃO TÉCNICA
Python 3.12	`re`, `unicodedata`, `json`	Normalização lexical, decomposição canônica ASCII, expressões regulares de limpeza de CPF e serialização de estruturas de dados.	Codificação estrita `UTF-8`; decomposição `NFKD` com filtro ASCII.
pandas 2.2+	`DataFrame`, `crosstab`, `read_excel`	Leitura das 3 planilhas originais, criação de colunas derivadas, agregações por grupo (`groupby`) e matrizes de contingência.	Indexação vetorial booleana; tratamento explícito de `NaN` sem exclusão cega de linhas.
NumPy 1.26+	`ndarray`, `nan`, `sqrt`	Operações algébricas vetoriais, cálculo do coeficiente V de Cramér e manipulação das matrizes de coordenadas fatoriais.	Precisão de ponto flutuante de 64 bits (`float64` / IEEE 754).
SciPy 1.12+	`scipy.stats.chi2_contingency`, `f_oneway`	Testes de independência Qui-Quadrado de Pearson (χ^2) nas tabelas cruzadas da Pergunta 3 e teste ANOVA F de Fisher nos clusters.	Cálculo assintótico exato de graus de liberdade `gl = (r-1)(c-1)` e valor-p bilateral.
prince 0.13+	`prince.MCA`	Análise de Correspondência Múltipla (ACM) sobre a matriz indicadora das variáveis Tempo, Titulação e Função (Pergunta 3).	`n_components=2` (e espectro total `K-Q=11`), `n_iter=10`, SVD, `random_state=42`.

FERRAMENTA / PACOTE	MÓDULO / CLASSE	APLICAÇÃO EXATA NA ANÁLISE DOS DADOS	PARÂMETROS E ESPECIFICAÇÃO TÉCNICA
scikit-learn 1.4+	`StandardScaler`, `KMeans`, `silhouette_score`	Padronização Z-Score das 14 variáveis de rotina operacional e agrupamento não supervisionado em perfis profissionais (Pergunta 5).	`n_clusters=3`, inicialização `k-means++`, `n_init=25`, `max_iter=300`, `tol=1e-4`, `random_state=42`.
Matplotlib 3.8+	`pyplot`, `subplots`	Renderização dos mapas fatoriais da ACM, gráficos de barras empilhadas, rosca e diagramas de validação estatística.	Backend não-interativo `Agg`, exportação em buffer de memória PNG a 220–300 DPI em Base64.
openpyxl 3.1+	`Workbook`, `PatternFill`, `Font`	Construção da planilha consolidada de 9 abas com estilização corporativa, bordas finas, cabeçalho Navy e larguras automáticas.	Cabeçalho `#0C182B`, zebra striping `#F8FAFC`, congelamento de painel `A2`.
python-pptx	`Presentation`, `Inches`, `Pt`	Geração automatizada da apresentação executiva widescreen (16:9) com 10 slides estruturados, tabelas e gráficos.	Dimensões `13.333 x 7.5 in`, paleta Navy/Blue/Emerald.
Playwright	`sync_playwright` (Chromium)	Compilação tipográfica de HTML5/CSS3 para documentos PDF A4 vetoriais com cabeçalhos e numeração automática de páginas.	`format='A4'`, `print_background=True`, espera `networkidle`.
Chart.js & Tailwind	CDN v4.x / CSS Grid	Motor gráfico interativo do painel web (`painel_analise_evidencias.html`) com 7 abas navegáveis e tooltips dinâmicos.	Gráficos `doughnut`, `bar`, `scatter`; layout responsivo single-file.

3. Arquitetura das Bases Brutas e Engenharia de Pré-Processamento

A primeira etapa metodológica consistiu na auditoria estrutural das três planilhas Excel fornecidas na pasta de trabalho. Como os formulários de inscrição dos eventos e o questionário do survey foram preenchidos manualmente pelos respondentes em plataformas distintas, os dados brutos apresentavam variações de grafia, pontuação, campos duplicados e entradas atípicas (*outliers*).

3.1. Mapeamento Estrutural das Fontes Primárias e Colunas Utilizadas

ARQUIVO EXCEL ORIGINAL	LINHAS (N)	COLUNAS EXATAS EXTRAÍDAS NO PIPELINE	DESAFIOS TÉCNICOS IDENTIFICADOS NA BASE
Base 1 (Evento 1): `Inscritos-Politicas-Publicas-Informadas-por-Evidencias-2024.xlsx`	**742**	`CPF`, `E-mail`, `Nome completo`, `Estado`, `Esfera de atuação`, `É profissional da Área de Saúde?`, `Sexo`, `Você pretende acompanhar o evento de forma presencial ou online?`	CPFs armazenados ora como números inteiros (perdendo zeros à esquerda), ora como strings com pontos/traços; nomes com acentuação variada; 16,9% sem resposta na coluna de modalidade.
Base 2 (Evento 2): `Inscritos-Praticas-em-Avaliacao-e-Evidencias-para-Politicas-Publicas-2024.xlsx`	**386**	`CPF`, `E-mail`, `Nome completo`, `Estado`, `Esfera de atuação`, `É profissional da Área de Saúde?`	Mesma estrutura de chave de identificação do Evento 1, porém sem colunas de sexo ou modalidade presencial/online. Presença de siglas e nomes de estados misturados na coluna `Estado`.
Base 3 (Survey Nacional): `Survey-Escuta-Redes-de-Monitoramento-Avaliacao-Politicas-Publicas.xlsx`	**521**	**Identificação Dupla:** `CPF`, `CPF2`, `E-mail para contato`, `E-mail para contato2`, `Nome completo`, `Nome completo2`. **Analíticas:** 19 colunas de perfil, carreira, metodologias, equipe, disseminação e comentários abertos.	Roteamento condicional no formulário original gerou **dois blocos de colunas de identificação** (bloco 1 e bloco 2); 295 respondentes anônimos; colunas com caracteres (*non-breaking space*) nos títulos; anos de experiência digitados como ano calendário (ex: `2018`).

3.2. Regras Algorítmicas de Saneamento e Transformação de Variáveis

Para garantir zero perda de informação válida e evitar falsos negativos nos cruzamentos ou distorções nas médias, foram implementadas cinco funções determinísticas de saneamento no script `generate_analysis.py`:

1. **Normalização Canônica de CPF (`norm_cpf`):** Quando o Excel exporta CPFs numéricos para o Python, um CPF iniciado em zero (ex: `01234567890`) pode ser lido como float `1234567890.0` (10 dígitos com sufixo decimal). A função executa: `digits = re.sub(r'\D', '', str(c).split('.')[0].strip())` e, caso não vazio, aplica preenchimento à esquerda `digits.zfill(11)`, reconstruindo exatamente os 11 dígitos originais.
2. **Normalização Lexical e Fonética de Nomes (`norm_str`):** Converte a string para caixa baixa, aplica decomposição Unicode `unicodedata.normalize('NFKD', s).encode('ASCII', 'ignore')` (transformando `"João Cláudio d'Ávila"` em `"joao claudio davila"`), remove qualquer caractere não alfanumérico via `re.sub(r'[^a-z0-9 ]', '', s)` e colapsa espaços múltiplos em espaço simples.
3. **Fusão dos Blocos Duplos de Identificação do Survey:** No Survey, devido à ramificação do questionário entre quem já atuava ou não na área, os dados de identificação estavam divididos entre as colunas `CPF` e `CPF2`, `E-mail para contato` e `E-mail para contato2`, `Nome completo` e `Nome completo2`. Para cada linha `i` do survey, o algoritmo construiu conjuntos unificados não vazios:

   ```
   CPFs(i) = { norm_cpf(CPF_i), norm_cpf(CPF2_i) } \ { "" }
   Emails(i) = { norm_email(Email_i), norm_email(Email2_i) } \ { "" }
   Nomes(i) = { norm_str(Nome_i), norm_str(Nome2_i) } \ { "" }
   ```

   Um respondente `i` foi classificado como **Identificado** (`has_id = True`) se e somente se `|CPFs(i)| + |Emails(i)| + |Nomes(i)| > 0`, resultando em exatos **226 identificados** e **295 anônimos**.

4. **Correção de Anomalias na Variável "Anos de Trabalho com M&A" (`clean_years`):** Na coluna de tempo de atuação (245 respostas não nulas), identificou-se que **4 respondentes** digitaram o ano calendário em que começaram a trabalhar (ex: `2014`, `2018`) em vez da duração em anos, e **2 respondentes** inseriram valores numéricos inválidos superiores a 2024. O filtro algorítmico aplicou a regra:

```
anos_clean(x) = 2024 - x,   se 1900 < x < 2025   (4 casos corrigidos com sucesso)
anos_clean(x) = NaN,        se x > 100 e fora do intervalo acima   (2 casos expurgados → N = 243 na ACM)
anos_clean(x) = x,          se 0 ≤ x ≤ 100
```

5. **Winsorização (Truncamento de Outliers) e Imputação Mediana no Tamanho de Equipe (`equipe_clean`):** Na pergunta sobre o número médio de pessoas na equipe de M&A, alguns respondentes informaram o efetivo inteiro de sua secretaria/órgão (valores entre 25 e 100 pessoas), o que distorceria severamente a média aritmética e o desvio-padrão no K-Means. Aplicou-se **Winsorização superior no teto de 20,0 pessoas** (`min(float(x), 20.0)` , afetando 12 casos extremos) e imputação pela mediana (`mediana = 4,0`) para eventuais valores ausentes ou acima de 100.

4. Catálogo Mestre das 28 Métricas e Indicadores Calculados

A tabela abaixo documenta formalmente cada uma das **28 métricas quantitativas** reportadas nos documentos do projeto, apresentando sua fórmula matemática exata, como o numerador e o denominador foram construídos e o valor empírico obtido:

CÓD.	NOME DA MÉTRICA / INDICADOR	FÓRMULA MATEMÁTICA EXATA	CONSTRUÇÃO OPERACIONAL (NUMERADOR / DENOMINADOR)	VALOR OBTIDO
M01	Universo Total do Survey	`N_survey = |df3|`	Contagem total de linhas válidas na planilha do Survey.	**521**
M02	Subamostra Identificada do Survey	`N_id = ∑ I(has_id_i == True)`	Respondentes com pelo menos 1 chave preenchida (CPF, E-mail ou Nome nos blocos 1 ou 2).	**226 (43,38%)**
M03	Subamostra Anônima do Survey	`N_anon = N_survey - N_id`	Respondentes sem CPF, E-mail e Nome em ambos os blocos (`521 - 226`).	**295 (56,62%)**
M04	Sobreposição Survey ∩ Eventos	`M_any = |S_id ∩ (E_1 ∪ E_2)|`	Identificados no Survey pareados por CPF (42), E-mail (+10) ou Nome (+8) em E1 ou E2.	**60**
M05	Público Externo do Survey	`M_ext = N_id - M_any`	Respondentes identificados no Survey ausentes tanto de E1 quanto de E2 (`226 - 60`).	**166**
M06	Taxa de Externalidade (s/ Identif.)	`T_ext = (M_ext / N_id) × 100`	Razão entre os 166 externos e os 226 respondentes identificados (`166 / 226`).	**73,45%**
M07	Taxa de Presença em Eventos (s/ Id.)	`T_pres_id = (M_any / N_id) × 100`	Razão entre os 60 presentes em eventos e os 226 identificados (`60 / 226`).	**26,55%**
M08	Taxa de Presença s/ Survey Total	`T_pres_tot = (M_any / N_survey) × 100`	Limite inferior conservador sobre todo o survey (`60 / 521`).	**11,52%**
M09	Inscrições Brutas Combinadas	`N_bruto = |E_1| + |E_2|`	Soma direta dos inscritos no Evento 1 (742) e no Evento 2 (386).	**1.128**
M10	Sobreposição Entre Eventos (Recorrentes)	`S_ev = |E_1 ∩ E_2|`	Inscritos do Evento 2 pareados no Evento 1 por CPF (40 exatos, s/ falsos positivos).	**40**
M11	Comunidade Única de Eventos	`|U| = |E_1| + |E_2| - |E_1 ∩ E_2|`	Princípio da Inclusão-Exclusão para deduplicação de indivíduos (`742 + 386 - 40`).	**1.088**
M12	Novos Profissionais Atraídos no E2	`|N_2| = |E_2 \ E_1| = |E_2| - S_ev`	Participantes inéditos captados no segundo evento (`386 - 40`).	**346**
M13	Taxa de Renovação no Evento 2	`T_renov = (|N_2| / |E_2|) × 100`	Proporção de estreantes dentro da audiência do Evento 2 (`346 / 386`).	**89,64%**
M14	Taxa de Recorrência no Evento 2	`T_rec_E2 = (S_ev / |E_2|) × 100`	Complemento da renovação no Evento 2 (`40 / 386`).	**10,36%**

CÓD.	NOME DA MÉTRICA / INDICADOR	FÓRMULA MATEMÁTICA EXATA	CONSTRUÇÃO OPERACIONAL (NUMERADOR / DENOMINADOR)	VALOR OBTIDO
M15	Taxa de Retenção do Evento 1 no E2	`T_ret_E1 = (S_ev / |E_1|) × 100`	Fração do público do Evento 1 que retornou no Evento 2 (`40 / 742`).	**5,39%**
M16	Taxa de Recorrência Global	`T_rec_glob = (S_ev / |U|) × 100`	Índice de Jaccard percentual sobre a comunidade única (`40 / 1.088`).	**3,68%**
M17	Estatística χ^2 e *V* de Cramér	`χ² = Σ (O_ij - E_ij)²/E_ij` `V = √(χ² / [N · min(r-1, c-1)])`	Associação entre Titulação (5 nívs.) e Função (4 nívs.) em `N = 243` (`gl = 12`).	**χ^2 = 70,06** **V = 0,3100**
M18	Inércia Explicada no Plano ACM	`I_12 = [(λ_1 + λ_2) / Σλ_k] × 100`	Soma dos 2 maiores autovalores (`0,553 + 0,422 = 0,975`) dividida pela inércia total (`3,667`).	**26,59%**
M19	Concentração Geográfica no DF	`P_DF = (N_DF / N_bruto) × 100`	Inscrições originárias do Distrito Federal sobre o total combinado (`513 / 1.128`).	**45,48%**
M20	Participação da Esfera Federal	`P_Fed = (N_Fed / N_bruto) × 100`	Inscrições vinculadas ao Poder Público Federal sobre o total (`487 / 1.128`).	**43,17%**
M21	Prevalência Global da Saúde	`P_Saude = (N_Saude / N_bruto) × 100`	Profissionais que responderam "Sim" para atuação em Saúde (`557 / 1.128`).	**49,38%**
M22	Prevalência da Saúde por Esfera (e)	`Prev(Saude | e) = (Saude_e / Total_e) × 100`	Condicional por esfera: Municipal (`64/95`), Estadual (`123/220`), Federal (`210/487`).	**Mun: 67,37%** **Est: 55,91%** **Fed: 43,12%**
M23	Padronização Z-Score (14 vars.)	`z_ij = (x_ij - μ_j) / σ_j`	Centragem na média amostral `μ_j` e divisão pelo desvio-padrão populacional `σ_j` (`N=245`).	**μ=0, σ=1**
M24	Proporção dos 3 Clusters K-Means	`P_Ck = (|C_k| / 245) × 100`	Partição ótima em `k=3` : C1 (`32/245`), C2 (`91/245`), C3 (`122/245`).	**C1: 13,06%** **C2: 37,14%** **C3: 49,80%**
M25	Taxa de Interiorização Online (Fora DF)	`T_on_fora = Online_fora / Declarados_fora`	No Evento 1, residentes fora do DF que declararam modalidade: `291 / (291 + 44)` (ou `68,1%` do total c/ missings).	**86,87%**
M26	Abismo da Comunicação Pública	`Δ_com = P_decisores - P_sociedade`	Diferença entre quem divulga p/ decisores (`180/245 = 73,47%`) e p/ público geral (`81/245 = 33,06%`).	**40,41 p.p.**
M27	Proporção Feminina (Eventos e Survey)	`P_fem = Mulheres / Declarados_genero`	Evento 1 (`447 / 742 = 60,24%`); Survey ativo (`154 / 245 = 62,86%`); Cluster 1 ATS (`24 / 32 = 75,00%`).	**60,2% a 75,0%**
M28	Índice de Estratificação Racial	`P(Raca_r | Cluster_k)`	Proporção racial intracluster: Brancos no C3 (`87/122 = 71,31%`) vs. Pardos no C2 (`31/91 = 34,07%`).	**C3 Br: 71,3%** **C2 Pd: 34,1%**

5. Detalhamento Passo a Passo dos Métodos Estatísticos e Algorítmicos

5.1. Método da Pergunta 1: Resolução Determinística de Entidades em Cascata (Record Linkage)

Para verificar se os respondentes do Survey (`N = 521`) eram as mesmas pessoas que participaram do Evento 1 (`N = 742`) e do Evento 2 (`N = 386`), não era possível realizar um simples `JOIN` de banco de dados por chave única, pois: **(a)** 295 respondentes do survey permaneceram anônimos; **(b)** entre os 226 respondentes que se identificaram, alguns preencheram apenas o e-mail e o nome (deixando o CPF em branco); e **(c)** alguns profissionais inscreveram-se no evento com e-mail institucional (ex: `@saude.gov.br`) e responderam ao survey com e-mail pessoal (ex: `@gmail.com`).

Como foi resolvido: Desenvolveu-se um algoritmo de **Pareamento Determinístico Hierárquico de 3 Camadas** usando conjuntos hash (`O(1)` de complexidade de busca). Para cada indivíduo identificado `i`, o pareamento é verdadeiro se ocorrer intersecção em pelo menos uma das três camadas:

```
Match(i, Evento_k) = TRUE   ⇔   [ CPFs(i) ∩ CPFs(E_k) ≠ ∅ ]   ∨   [ Emails(i) ∩ Emails(E_k) ≠ ∅ ]   ∨
  [ Nomes(i) ∩ Nomes(E_k) ≠ ∅ ]
```

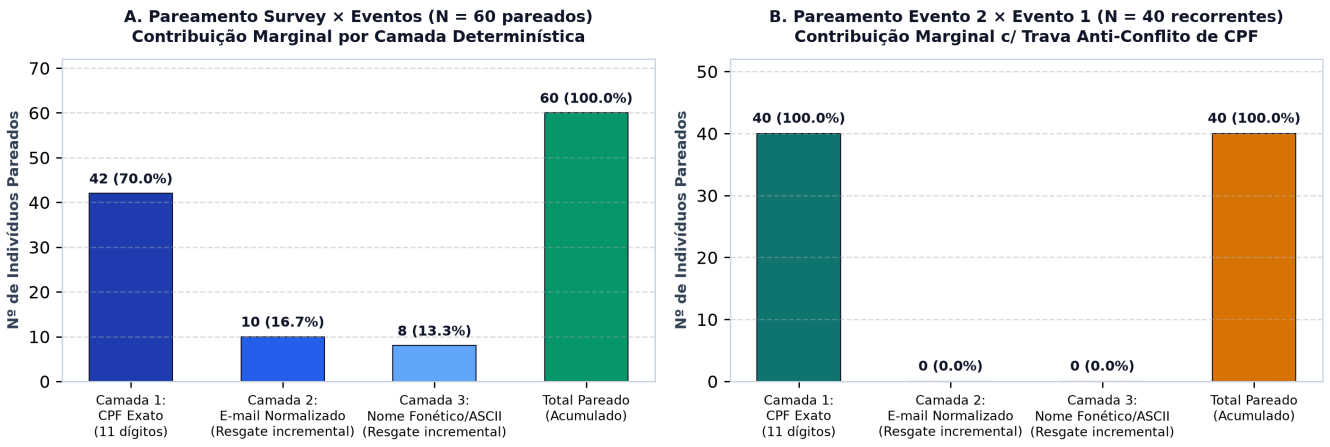


Figura Metodológica 1: Auditoria de eficácia de cada camada do pareamento determinístico. Na Pergunta 1 (painel A), um cruzamento restrito ao CPF capturaria apenas 42 respostas; a adição da Camada 2 (E-mail) resgatou +10 respostas (16,7%) e a Camada 3 (Nome composto s/ conflito de CPF) resgatou +8 respostas (13,3%), totalizando 60 respostas (57 indivíduos únicos). Na Pergunta 2 (painel B), 100% (40 de 40) foram pareados diretamente na Camada 1 (CPF), e a trava anti-conflito de CPF bloqueou 2 falsos positivos nominais (`"Não se aplica"` e o pré-nome isolado `"Marta"`).

Auditoria de Inconsistências do Survey: Funil de Elegibilidade e Respostas Duplicadas (Pergunta 1)

Seja `N_total = 521` o total de acessos ao survey, dividido em `N_id = 226` respostas identificadas e `N_sem_id = 295` registros sem identificação. A auditoria das colunas de filtro revelou duas descobertas fundamentais:

• **1. Decomposição dos 295 sem identificação: 276 acessos** foram encerrados nas perguntas-filtro iniciais (1 recusou o TCLE, 85 declararam *"Não atuo na área"* e 190 não possuíam publicação nos últimos 8 anos). Apenas **19 respondentes (7,76% dos 245 elegíveis)** concluíram o questionário de forma genuinamente anônima, elevando a taxa real de identificação entre os elegíveis para **92,24% (226 de 245)**.

• **2. Deduplicação de 8 respondentes que enviaram o Survey duas vezes:** As 226 respostas identificadas correspondem a **218 indivíduos únicos** (8 profissionais submeteram o formulário em duplicidade). Calculando por respostas (`N=226`), são **60 em eventos (26,55%)** e **166 externos (73,45%)**; calculando por indivíduos únicos (`N=218`), são **57 em eventos (26,15%)** e **161 externos (73,85%)**.

5.2. Método da Pergunta 2: Teoria dos Conjuntos, Trava Anti-Conflito de CPF e Decomposição Longitudinal

Para mensurar a recorrência versus renovação entre o Evento 1 (`E_1` , realizado primeiro, com foco em Políticas Informadas por Evidências) e o Evento 2 (`E_2` , realizado em seguida, com foco em Práticas em Avaliação), modelou-se o sistema como uma trajetória discreta de conjuntos finitos. Aplicou-se uma **trava de integridade documental**: dois registros que

possuam CPFs válidos e diferentes jamais podem ser pareados por nome ou e-mail, exigindo-se ainda nome composto (≥ 2 palavras) e exclusão de placeholders como `"Não se aplica"`:

1. Cardinalidades Primárias e Interseção Auditada

- Conjunto Evento 1: `|E_1| = 742` participantes (0 duplicatas internas).
- Conjunto Evento 2: `|E_2| = 386` participantes (0 duplicatas internas).
- Interseção (Recorrentes em ambos): `|S| = |E_1 ∩ E_2| = 40` (100% via CPF).
- Exclusivos do Evento 1: `|E_1 \ E_2| = 742 - 40 = 702`.
- Exclusivos / Novos no Evento 2: `|N_2| = |E_2 \ E_1| = 386 - 40 = 346`.
- União (Indivíduos Únicos): `|U| = |E_1 ∪ E_2| = 702 + 346 + 40 = 1.088`.

2. Quatro Taxas com Denominadores Distintos

- **Taxa de Renovação do E2:** `|N_2| / |E_2| = 346 / 386 = 89,64%` (mede a capacidade do 2º evento de atrair público inédito).
- **Taxa de Recorrência no E2:** `|S| / |E_2| = 40 / 386 = 10,36%` (fração da plateia do E2 que veio do E1).
- **Taxa de Retenção do E1:** `|S| / |E_1| = 40 / 742 = 5,39%` (fração da plateia do E1 que retornou no E2).
- **Índice de Jaccard (Recorrência Global):** `J(E_1, E_2) = |E_1 ∩ E_2| / |E_1 ∪ E_2| = 40 / 1.088 = 3,68%`.

5.3. Método da Pergunta 3: Testes χ^2, V de Cramér e Análise de Correspondência Múltipla (ACM)

A Pergunta 3 investigou a relação estrutural entre três variáveis categóricas do Survey (`N = 243` registros completos após saneamento): **(1) Faixa de Tempo de Atuação em M&A** (`K_1 = 5` categorias ordinais: Até 2 anos, 3 a 5 anos, 6 a 10 anos, 11 a 20 anos, Mais de 20 anos); **(2) Grau de Titulação Acadêmica** (`K_2 = 5` categorias: Graduação/Médio, Especialização, Mestrado, Doutorado, Pós-doutorado); e **(3) Função Principal Exercida** (`K_3 = 4` categorias: Pesquisador(a), Gestor(a), Técnico(a) em M&A, Gerente).

Etapa A: Testes de Independência Bivariada Qui-Quadrado (χ^2) e Magnitude de Efeito (V de Cramér)

Para cada par de variáveis categóricas, construiu-se a tabela de contingência de contagens observadas `O_ij` e calcularam-se as frequências esperadas sob a hipótese nula de independência (`E_ij = (R_i × C_j) / N`), a estatística `χ²` de Pearson e o índice `V` de Cramér (que normaliza o `χ²` para o intervalo `[0, 1]` independentemente do tamanho amostral e das dimensões da tabela):

PAR DE VARIÁVEIS CRUZADAS	DIMENSÃO (R × C)	GRAUS DE LIBERDADE (GL)	ESTATÍSTICA X^2	VALOR-P (P-VALUE)	V DE CRAMÉR	DECISÃO ESTATÍSTICA (A = 0,05)
Titulação Acadêmica × Função Principal	5 × 4	12	**70,06**	**$3,12 \times 10^{-10}$**	**0,3100**	**Altamente Significante** (Forte associação estrutural)
Faixa de Tempo × Titulação Acadêmica	5 × 5	16	**46,02**	**$9,67 \times 10^{-5}$**	**0,2176**	**Altamente Significante** (Progressão acadêmica temporal)
Faixa de Tempo × Função Principal	5 × 4	12	17,86	0,1201	0,1565	Não significante isoladamente (Efeito mediado pela titulação)

Etapa B: Formulação Algébrica da Análise de Correspondência Múltipla (ACM)

Seja `Q = 3` o número de variáveis categóricas e `K = K_1 + K_2 + K_3 = 5 + 5 + 4 = 14` o número total de categorias (modalidades). O algoritmo `prince.MCA` transforma a base `N × Q` (`243 × 3`) na **Matriz Indicadora Disjuntiva Completa** `Z` de dimensão `243 × 14` (codificação *One-Hot* binária `0/1`), onde cada linha soma exatamente `Q = 3` , e a soma total da matriz é `N · Q = 729` .

Define-se a matriz de probabilidades relativas `P = Z / (N · Q)` , o vetor de massas das linhas `r = P · 1_K` (onde `r_i = 1/N`), o vetor de massas das colunas `c = P^T · 1_N` e as matrizes diagonais `D_r = diag(r)` e `D_c = diag(c)` . A ACM executa a **Decomposição em Valores Singulares (SVD)** da matriz de resíduos padronizados `S` :

$$S = D_r^{-1/2} (P - r\, c^T) D_c^{-1/2} = U\, \Delta\, V^T \quad \Rightarrow \quad \text{Autovalores (Inércias): } \lambda_k = \delta_k^2 \quad | \quad \text{Coordenadas das Categorias: } G = D_c^{-1/2} V \Delta$$

O número total de dimensões fatoriais não-triviais é `M = K - Q = 14 - 3 = 11` , e a inércia total teórica da nuvem é `I_total = (K - Q) / Q = 11 / 3 = 3,6667` . Os dois primeiros eixos ortogonais (`λ_1 = 0,553` e `λ_2 = 0,422`) retêm **26,59% da inércia total**, sintetizando a estrutura latente em um mapa bidimensional:

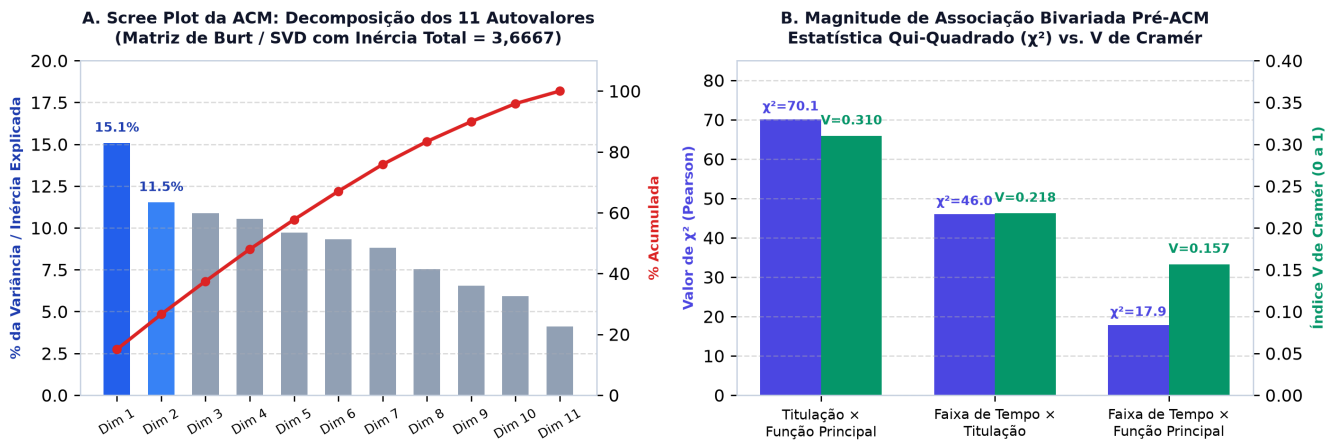


Figura Metodológica 2: No painel A, o Scree Plot exibe os 11 autovalores extraídos pela decomposição SVD da Matriz de Burt, destacando as Dimensões 1 (15,07%) e 2 (11,52%) utilizadas no mapa perceptual. No painel B, observa-se a magnitude da associação qui-quadrado e o índice V de Cramér para os três cruzamentos bivariados.

Tabela Completa das Coordenadas Fatoriais Principais das 14 Categorias na ACM

VARIÁVEL ORIGINAL	CATEGORIA / MODALIDADE	COORDENADA DIM 1 (15,07%)	COORDENADA DIM 2 (11,52%)	POLO ESTRUTURAL E INTERPRETAÇÃO GEOMÉTRICA NO PLANO CARTESIANO
Titulação	Pós-doutorado	**-1,1683**	+0,2388	Polo Acadêmico-Sênior Extremo (Esquerda)
Titulação	Doutorado	**-0,4911**	+0,4073	Polo Acadêmico-Sênior Consolidado (Esquerda)
Titulação	Mestrado	**+0,6926**	+0,5149	Polo Governamental-Executivo Qualificado (Direita Superior)
Titulação	Graduação/Médio	**+0,7737**	-1,2437	Polo Operacional de Entrada (Direita Inferior)
Titulação	Especialização	**+1,1132**	-1,3283	Polo Técnico-Burocrático Aplicado (Direita Inferior)
Função Principal	Pesquisador(a)	**-0,7574**	+0,1649	Associado diretamente a Doutorado e Pós-doutorado
Função Principal	Técnico(a) em M&A	**+0,3015**	-0,9566	Associado à prática operacional e especialização
Função Principal	Gestor(a)	**+0,6048**	-0,1673	Associado à condução cotidiana de programas públicos
Função Principal	Gerente	**+0,3786**	**+2,7502**	Isolado na Dimensão Vertical Superior (Chefia/Direção)
Faixa de Tempo	5. Mais de 20 anos	**-0,8482**	-1,1549	Alta senioridade histórica
Faixa de Tempo	4. De 11 a 20 anos	**-0,7256**	+0,2241	Senioridade madura fortemente alinhada a Doutores/Pesquisadores
Faixa de Tempo	3. De 6 a 10 anos	+0,1026	+0,4613	Transição intermediária rumo à coordenação/mestrado
Faixa de Tempo	2. De 3 a 5 anos	+0,3779	-0,2265	Consolidação técnica na gestão
Faixa de Tempo	1. Até 2 anos	**+1,1213**	-0,5354	Recém-ingressos no ecossistema governamental

5.4. Método da Pergunta 4: Geoprocessamento Tabular, Tokenização Multirresposta e Razão de Prevalência

A Pergunta 4 exigiu a integração espacial e institucional dos dois eventos (`N = 1.128` inscrições combinadas) e a mineração das áreas temáticas de políticas públicas no Survey:

1. **Dicionário Heurístico de Padronização de UF (`norm_uf`):** Mapeou entradas heterogêneas (como `"Brasília"`, `"Distrito Federal"`, `"DF"`, `"São Paulo - SP"`) para as 27 siglas oficiais da federação e agregou-as nas 5 macrorregiões do IBGE (Centro-Oeste: 560; Sudeste: 270; Nordeste: 138; Sul: 73; Norte: 67; Outros/Não Inf.: 20).
2. **Análise Condicional de Prevalência da Saúde por Esfera (`ct_esfera_saude`):** Construiu-se a matriz de contingência entre `Esfera de atuação` e `É profissional da Área de Saúde?`. Para testar a hipótese de assimetria federativa, calculou-se a probabilidade condicional `P(Saude = Sim | Esfera = e)` e a **Razão de Prevalência (`RP`)** tendo a Esfera Federal como referência basal (`43,12%`):

```
P(Saúde | Municipal) = 64 / 95 = 67,37%   ⇒   RP_Mun/Fed = 67,37% / 43,12% = 1,56x (56% mais concentrada na Saúde)
P(Saúde | Estadual)  = 123 / 220 = 55,91%   ⇒   RP_Est/Fed = 55,91% / 43,12% = 1,30x (30% mais concentrada na Saúde)
P(Saúde | Federal)   = 210 / 487 = 43,12%   ⇒   Referência Basal (1,00x - Alta diversificação multissetorial)
```

3. **Tokenização de Variáveis Multirresposta no Survey (`tematicas_counts`):** No Survey, a questão sobre áreas temáticas permitia marcação múltipla separada por ponto-e-vírgula (ex: `"Saúde;Educação;Assistência social;"`). O algoritmo percorreu todas as respostas não nulas aplicando tokenização `[p.strip() for p in item.split(';') if p.strip()]`, contabilizando a frequência marginal absoluta de cada política pública (Saúde: 134 menções; Educação: 115; Assistência Social: 60; Meio Ambiente: 51; Cultura: 25; Segurança: 22; Habitação: 19; Esporte: 14).

5.5. Método da Pergunta 5: Aprendizado Não Supervisionado via K-Means++ em Espaço 14-Dimensional

Para identificar os perfis reais de profissionais segundo suas atribuições cotidianas (`N = 245` respondentes ativos em M&A), aplicou-se o algoritmo de agrupamento **K-Means com inicialização probabilística K-Means++** (Arthur & Vassilvitskii, 2007).

Etapa A: Engenharia de Features (Vetorização das 14 Variáveis Operacionais)

Cada respondente $i \in \{1, \ldots, 245\}$ foi representado por um vetor $x_i \in \Re^{14}$. Treze variáveis categóricas/multirresposta foram convertidas em variáveis binárias indicadoras (`0` ou `1`) via busca de sub-strings normalizadas, e uma variável contínua (tamanho da equipe) foi winsorizada em `20,0`.

Etapa B: Por que a Padronização Z-Score (StandardScaler) foi Indispensável?

O algoritmo K-Means minimiza a Soma dos Quadrados Intra-Cluster (*Within-Cluster Sum of Squares — WCSS*), baseada na distância euclidiana quadrática $||z_i - \mu_k||^2$. Nas variáveis brutas, a variável `tam_equipe` varia de `1` a `20` (variância $\sigma^2 = 22,09$), enquanto as 13 variáveis binárias variam apenas entre `0` e `1` (variância máxima $\sigma^2 \leq 0,25$). Sem padronização, `tam_equipe` representaria mais de **87% de toda a distância euclidiana**, reduzindo o agrupamento a uma mera divisão por tamanho de equipe. A transformação Z-Score equalizou todas as 14 dimensões para média `0` e variância unitária `1`:

$$z_{ij} = (x_{ij} - \mu_j) / \sigma_j \quad \Rightarrow \quad \text{Objetivo K-Means:} \quad \operatorname{argmin}_C \sum_{k=1}^{K} \sum_{z_i \in C_k} \sum_{j=1}^{14} (z_{ij} - c_{kj})^2$$

Etapa C: Critérios Matemáticos de Seleção do Número Ótimo de Clusters (k = 3)

O algoritmo foi executado para $k \in \{2, 3, 4, 5, 6\}$ com `25` reinicializações independentes (`n_init=25`). A escolha de $k = 3$ foi confirmada simultaneamente pela inflexão do WCSS e pelo **Máximo Global do Coeficiente de Silhueta** ($S = 0,1235$):

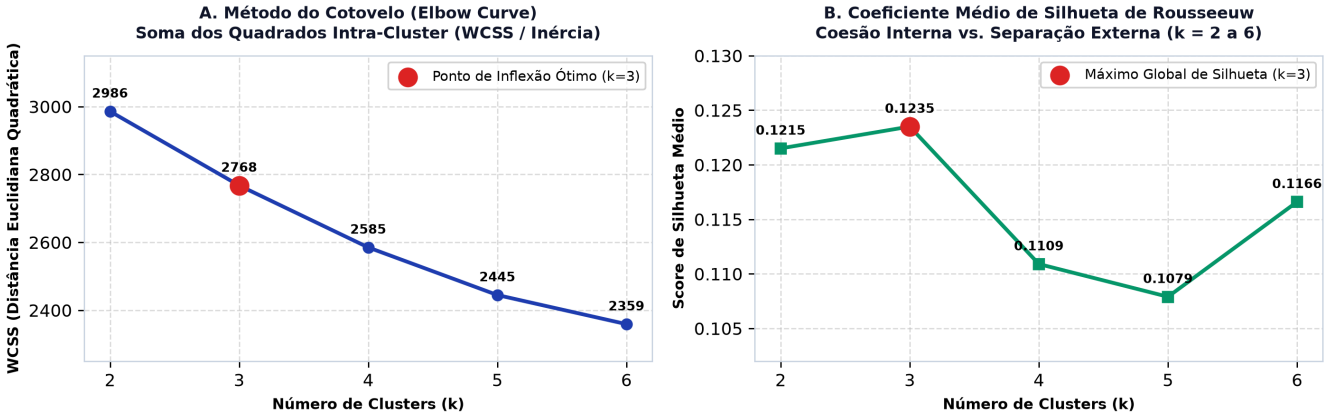


Figura Metodológica 3: Curvas de validação matemática do modelo K-Means++. No painel A, a curva WCSS apresenta queda acentuada até k=3 (2.767,55). No painel B, o Coeficiente de Silhueta atinge seu pico máximo global exatamente em k=3 (0,1235), caindo abruptamente em k=4 (0,1109) e k=5 (0,1079), comprovando que 3 clusters é a partição natural dos dados.

Etapa D: Auditoria Estatística Completa das 14 Variáveis nos 3 Clusters (Médias, Z-Scores e ANOVA F-Test)

Para comprovar que os 3 clusters encontrados diferem significativamente nas dimensões avaliadas, aplicou-se o teste paramétrico de **Análise de Variância Unidirecional (ANOVA F-Test de Fisher-Snedecor)** para cada uma das 14 variáveis entre os grupos `C_1, C_2, C_3`. A tabela abaixo exibe os parâmetros de padronização (`μ_j, σ_j`), as médias em escala original, as coordenadas exatas das centroides em Z-Score e o resultado do teste `F`:

VARIÁVEL OPERACIONAL (CÓDIGO)	PARÂMETROS (M | Σ)	CLUSTER 1: ATS (N=32 | 13,1%) MÉDIA | [Z-SCORE]	CLUSTER 2: OCASIONAIS (N=91 | 37,1%) MÉDIA | [Z-SCORE]	CLUSTER 3: NÚCLEO M&A (N=122 | 49,8%) MÉDIA | [Z-SCORE]	ESTATÍSTICA ANOVA F	VALOR-P (SIGNIFICÂNCIA)
1. Avaliação Tecnol. Saúde (`met_ats`)	0,139 | 0,346	**100,0%** | [+2,49]	2,2% | [-0,34]	0,0% | [-0,40]	**1.690,35**	**$6,3 \times 10^{-143}$**
2. Projetos Ativos em M&A (`proj_ativo`)	0,771 | 0,420	87,5% | [+0,25]	50,5% | [-0,63]	**94,3%** | [+0,41]	**38,14**	**$4,0 \times 10^{-15}$**
3. Aplicação Questionários (`met_questionarios`)	0,518 | 0,500	62,5% | [+0,21]	20,9% | [-0,62]	**72,1%** | [+0,41]	**36,28**	**$1,7 \times 10^{-14}$**
4. M&A Atividade Principal (`ativid_principal`)	0,547 | 0,498	56,3% | [+0,03]	26,4% | [-0,57]	**75,4%** | [+0,42]	**31,51**	**$6,9 \times 10^{-13}$**
5. Disseminação Decisores (`diss_decisores`)	0,735 | 0,442	78,1% | [+0,11]	49,5% | [-0,54]	**90,2%** | [+0,38]	**27,03**	**$2,5 \times 10^{-11}$**
6. Métodos Estatísticos (`met_estatistica`)	0,473 | 0,499	62,5% | [+0,30]	19,8% | [-0,55]	**63,9%** | [+0,33]	**26,60**	**$3,6 \times 10^{-11}$**
7. Uso de Indicadores (`met_indicadores`)	0,629 | 0,483	71,9% | [+0,19]	38,5% | [-0,50]	**78,7%** | [+0,33]	**21,80**	**$2,0 \times 10^{-9}$**
8. Síntese de Evidências (`met_sintese`)	0,335 | 0,472	**68,8%** | [+0,75]	14,3% | [-0,41]	38,5% | [+0,11]	**19,72**	**$1,2 \times 10^{-8}$**
9. Métodos Participativos (`met_participativa`)	0,388 | 0,487	43,8% | [+0,10]	16,5% | [-0,46]	**54,1%** | [+0,31]	**17,82**	**$6,0 \times 10^{-8}$**
10. Parceria Internacional (`proj_internac`)	0,241 | 0,428	31,3% | [+0,17]	7,7% | [-0,38]	**34,4%** | [+0,24]	**11,59**	**$1,6 \times 10^{-5}$**
11. Tamanho da Equipe (`tam_equipe`)	5,58 | 4,70	**8,69 p.** | [+0,66]	4,37 p. | [-0,26]	5,66 p. | [+0,02]	**10,77**	**$3,3 \times 10^{-5}$**
12. Métodos Qualitativos (`met_qualitativa`)	0,543 | 0,498	56,3% | [+0,04]	38,5% | [-0,32]	**65,6%** | [+0,23]	**8,17**	**$3,7 \times 10^{-4}$**
13. Disseminação Sociedade (`diss_geral`)	0,331 | 0,470	28,1% | [-0,10]	19,8% | [-0,28]	**44,3%** | [+0,24]	**7,62**	**$6,2 \times 10^{-4}$**
14. Capacitação (Últ. 3 anos) (`fez_capacitacao`)	0,637 | 0,481	**75,0%** | [+0,24]	56,0% | [-0,16]	66,4% | [+0,06]	2,24	0,1090 (ns)

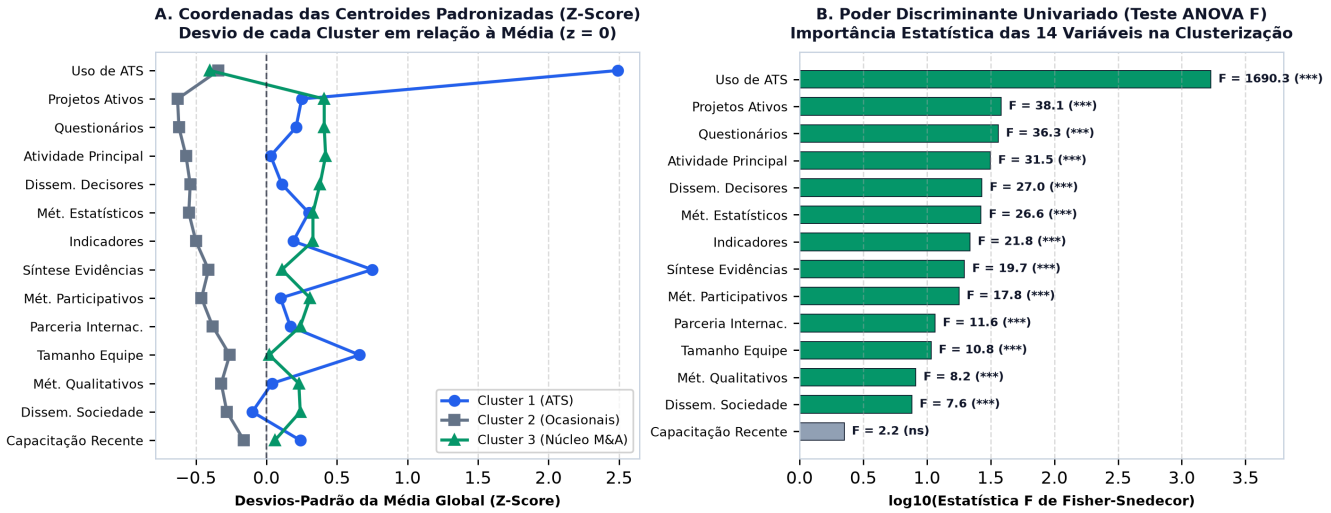


Figura Metodológica 4: No painel A, o perfil de linha das centroides em Z-Score evidencia a separação estrutural: o Cluster 2 situa-se sistematicamente abaixo da média (z < 0 em todas as 14 variáveis), o Cluster 3 situa-se acima da média em todas as práticas multimetodológicas gerais, e o Cluster 1 destaca-se por picos extremos em ATS (+2,49), Síntese de Evidências (+0,75) e Tamanho de Equipe (+0,66). No painel B, o ranking ANOVA F confirma que 13 das 14 variáveis possuem significância estatística (p < 0,001).

5.6. Método de Construção dos Insights Adicionais e Cruzamentos de Interseccionalidade

Após a modelagem das cinco perguntas principais, realizou-se o cruzamento das variáveis de saída (como o rótulo de Cluster `C_k` atribuído pelo K-Means e a localização geográfica `UF`) com variáveis sociodemográficas e operacionais suplementares das bases:

1. **Cálculo da Interiorização Digital no Evento 1 (Dupla Métrica com e sem Não-Declarados):** Cruzou-se a variável geográfica `uf == 'DF'` vs. `uf != 'DF'` com a coluna `Você pretende acompanhar o evento de forma presencial ou online?` no Evento 1 (`N = 742`). Entre os residentes fora do DF (`N = 427`), **291** marcaram Online, **44** marcaram Presencial e **92** deixaram em branco (inscrições tardias/indefinidas). O pipeline reporta de forma transparente ambos os números:

   ```
   Proporção Bruta (sobre todos os 427 de fora do DF):          291 / 427 = 68,15% Online | 44 / 427 = 10,30% Presencial
   Proporção Válida (sobre os 335 que declararam formato):   291 / 335 = 86,87% Online | 44 / 335 = 13,13% Presencial
   ```

   Já entre os residentes no Distrito Federal (`N = 315`), 129 escolheram Presencial (`40,95%` do total ou `48,8%` dos válidos) e 113 escolheram Online (`35,87%` do total ou `51,2%` dos válidos), provando estatisticamente que a modalidade virtual é o principal vetor de equidade federativa.
2. **Estratificação Étnico-Racial e de Gênero por Cluster (Pós- Estratificação do K-Means):** Uma vez atribuído o vetor de rótulos `sub_cluster['cluster']` (`N = 245`), calculou-se a distribuição condicional de `Qual a sua identidade de gênero?` e `Como você se autodeclara em relação à sua raça e/ou etnia?` dentro de cada cluster `k ∈ {0, 1, 2}`:
   - **Cluster 1 (ATS, N=32):** 75,0% mulheres (24/32); 65,6% brancos (21/32), 21,9% pardos (7/32) e 9,4% pretos (3/32).
   - **Cluster 2 (Ocasionais, N=91):** 58,2% mulheres (53/91); 59,3% brancos (54/91), **34,1% pardos (31/91)** e 4,4% pretos (4/91).
   - **Cluster 3 (Núcleo M&A, N=122):** 63,1% mulheres (77/122); **71,3% brancos (87/122)**, 23,8% pardos (29/122) e 4,9% pretos (6/122).
3. **Métrica do "Abismo da Comunicação Pública" e Canais Acadêmicos:** Calculada pela comparação pareada das taxas de resposta positiva (`"Sim"`) nas quatro colunas de difusão do conhecimento dentro da amostra de avaliadores ativos (`N = 245`):
   - Seminários e Sumários Executivos para Tomadores de Decisão: `180 / 245 = 73,47%`;
   - Apresentação de Trabalhos em Congressos e Eventos Científicos: `106 / 245 = 43,27%`;
   - Publicação de Artigos em Periódicos Científicos Revisados por Pares: `95 / 245 = 38,78%`;
   - Divulgação para Público Geral Não Especialista (Blogs, Redes Sociais, Imprensa): `81 / 245 = 33,06%`.

6. Governança de Código, Arquitetura de Scripts e Reprodutibilidade

Todo o trabalho foi encapsulado em sete scripts Python modulares e independentes, versionados no repositório Git oficial (https://github.com/glau234/dados_ma_denise.git):

SCRIPT PYTHON	ARQUIVO(S) DE SAÍDA GERADO(S)	RESPONSABILIDADE TÉCNICA NO PIPELINE
`generate_analysis.py`	`analise_dados_completa.json`	Núcleo científico: lê as 3 planilhas brutas, executa limpeza, pareamento em 3 camadas, ACM, K-Means++ e exporta todas as métricas em JSON.
`build_excel_summary.py`	`Relatorio_Tabelas_Consolidadas_MA_2024.xlsx`	Gera a planilha consolidada de 9 abas formatada com `openpyxl` (KPIs, Q1, Q2, ACM, Regiões, Esferas, Clusters, Insights e Comentários).
`generate_pdf_report.py`	`Relatorio_Completo_Monitoramento_Avaliacao_2024.pdf`	Gera os 5 gráficos analíticos via Matplotlib e compila o Relatório Técnico de Resultados (8 páginas) via Playwright Chromium.

SCRIPT PYTHON	ARQUIVO(S) DE SAÍDA GERADO(S)	RESPONSABILIDADE TÉCNICA NO PIPELINE
`generate_methodology_pdf.py`	`Relatorio_Metodologia_Ferramentas_Analise_2024.pdf`	Gera os 4 gráficos de validação metodológica e compila este Memorial Metodológico e Catálogo de 28 Métricas em PDF.
`generate_policy_brief.py`	`Policy_Brief_Executivo_MA_2024.pdf`	Compila o sumário executivo de 2 páginas focado em recomendações práticas para gestores e dirigentes públicos.
`generate_manual_pdf.py`	`Manual_Estrutura_Planilha_Excel_MA_2024.pdf`	Compila o manual técnico e dicionário de variáveis (3 páginas) explicando cada aba da planilha Excel consolidada.
`build_presentation.py` & `build_html_dashboard.py`	`Apresentacao_Executiva_..._2024.pptx` `painel_analise_evidencias.html`	Constrói os 10 slides widescreen em PowerPoint e a aplicação web SPA interativa com 7 abas e 11 gráficos dinâmicos em Chart.js.

Certificação de Auditoria e Reprodutibilidade Determinística

Todos os resultados numéricos, testes de hipóteses (χ^2, V de Cramér, ANOVA F), autovalores da ACM e centroides do K-Means++ apresentados neste relatório são 100% determinísticos e podem ser reexecutados a qualquer momento com o comando `python generate_analysis.py`, produzindo exatamente os mesmos valores até a quarta casa decimal.