DOCUMENTO METODOLÓGICO OFICIAL | CIÊNCIA DE DADOS & ECONOMETRIA | REPRODUTIBILIDADE ESTRITA

Relatório de Ferramentas, Métodos e Procedimentos Analíticos

Detalhamento técnico, algoritmos, equações matemáticas e fluxo computacional aplicados na análise dos dados de Monitoramento, Avaliação e Evidências em Políticas Públicas (2024)

LINGUAGEM & VERSÃO	ECOSSISTEMA MATEMÁTICO	AMOSTRAS ANALISADAS	CONTROLE DE VERSÃO
Python 3.12 (64-bit)	scikit-learn, prince, scipy	1.128 Inscrições | 521 Survey	Git / GitHub (main branch)

1. Apresentação e Escopo do Relatório

Este relatório tem por objetivo registrar e descrever formalmente todas as **ferramentas computacionais**, **pacotes de software**, **modelos estatísticos** e **procedimentos algorítmicos** empregados na análise integrada das bases de dados de participantes dos eventos nacionais e dos respondentes do survey de escuta da comunidade de Monitoramento e Avaliação (M&A) e Políticas Públicas Informadas por Evidências (PIE) no Brasil no ano-base de 2024.

A abordagem metodológica adotou o paradigma da **pesquisa quantitativa reproduzível** (*Reproducible Research*). Todas as transformações de dados, testes de hipóteses, reduções dimensionais e agrupamentos não supervisionados foram desenvolvidos em código aberto, parametrizados deterministicamente com sementes pseudo-aleatórias fixadas (`random_state=42`) e executados sem qualquer intervenção manual nas planilhas de origem, garantindo auditoria ponta a ponta e integridade analítica absoluta.

2. Inventário de Ferramentas, Linguagens e Bibliotecas

O ecossistema analítico foi estruturado sobre a linguagem de programação **Python**, complementada por bibliotecas especializadas em análise multivariada, computação científica, manipulação relacional, formatação de dados e renderização editorial de alta performance.

FERRAMENTA / BIBLIOTECA	CATEGORIA	FUNÇÃO ESPECÍFICA NO PROJETO	JUSTIFICATIVA TÉCNICA
Python 3.12	Linguagem Base	Ambiente principal de processamento de dados, orquestração de scripts e execução estatística.	Liderança na ciência de dados, ampla interoperabilidade e tipagem estrita moderna.
pandas (v2.2+)	Manipulação de Dados	Ingestão dos arquivos Excel (.xlsx), fusão relacional (merges), filtros e engenharia de variáveis.	Manipulação vetorial com alto desempenho em memória e suporte nativo a indexação multinível.
NumPy (v1.26+)	Computação Numérica	Cálculo matricial, transformações de vetores lógicos e álgebra linear subjacente.	Eficiência de baixo nível em C para operações matemáticas estruturadas em arrays.
scikit-learn (v1.4+)	Machine Learning	Algoritmo de agrupamento não supervisionado K-Means e padronização escalar Z-Score.	Implementação consagrada com algoritmo *k-means++* para convergência acelerada e estável.
prince (v0.13+)	Análise Multivariada	Execução da Análise de Correspondência Múltipla (ACM/MCA) e decomposição em valores singulares.	Especializado em matrizes indicadoras e matrizes de Burt para dados categóricos multidimensionais.
SciPy (scipy.stats)	Inferência Estatística	Testes Qui-Quadrado (χ^2) de Pearson para tabelas de contingência e cálculo de valores-p.	Precisão assintótica no cálculo de distribuições de probabilidade contínuas e discretas.
openpyxl (v3.1+)	Engenharia Excel	Geração programática da planilha consolidada (9 abas), estilização corporativa Navy e bordas.	Leitura e escrita de arquivos OpenXML nativos com controle fino de fontes, preenchimentos e formatos.
python-pptx	Comunicação Executiva	Montagem da apresentação corporativa em PowerPoint (10 slides widescreen 16:9).	Criação de apresentações ricas com cards analíticos e figuras vetoriais embutidas programaticamente.
Playwright Chromium	Diagramação PDF	Motor de renderização headless para compilação dos relatórios técnicos oficiais em PDF A4.	Fidelidade gráfica impecável a padrões editoriais modernos com suporte CSS Paged Media.
Tailwind CSS & Chart.js	Frontend Interativo	Construção do painel analítico web (HTML5) com gráficos interativos e responsivos.	Interface moderna, sem dependência de servidores de aplicação complexos (execução client-side).
Git & GitHub	Governança e Versão	Versionamento distribuído do código-fonte, dados derivados e sincronização com repositório remoto.	Rastreabilidade de commits convencionais e colaboração segura com gerenciamento de credenciais.

3. Bases de Dados e Engenharia de Pré-Processamento

A pesquisa consolidou três repositórios primários fornecidos em formato Microsoft Excel (.xlsx), totalizando 1.649 registros brutos. A tabela a seguir descreve a estrutura das fontes originais:

BASE DE DADOS PRIMÁRIA	REGISTROS BRUTOS	VARIÁVEIS CHAVE	NATUREZA DA AMOSTRA
Inscritos-Politicas-Publicas-Informadas-por-Evidencias-2024.xlsx	742 inscrições	Nome, E-mail, CPF, UF, Instituição, Esfera, Setor, Modalidade (Presencial/Online), Sexo	Participantes de evento nacional focado na interface entre evidências científicas e tomada de decisão.
Inscritos-Praticas-em-Avaliacao-e-Evidencias-2024.xlsx	386 inscrições	Nome, E-mail, CPF, UF, Órgão, Esfera, Formato de Inscrição	Participantes de fórum focado na prática metodológica e aplicação operacional de M&A.
Survey-Escuta-Redes-de-Monitoramento-Avaliacao.xlsx	521 respondentes	Dados demográficos, Carreira, Tempo de M&A, Métodos aplicados, Rotinas, Disseminação	Pesquisa nacional de escuta profissional estruturada com respondentes nominais e anônimos.

3.1. Pipeline de Limpeza e Normalização Textual

Devido à origem manual dos cadastros (digitação direta pelos participantes), foi desenvolvido um algoritmo rigoroso de higienização prévia para permitir o cruzamento determinístico:

- **Normalização de CPFs:** Aplicação de expressões regulares para extração exclusiva de algarismos numéricos (`re.sub(r'\D', '', str(cpf))`), validação de tamanho canônico de 11 dígitos com preenchimento de zeros à esquerda (`zfill(11)`) e expurgo de CPFs genéricos/inválidos (ex: sequências repetidas 111.111.111-11).
- **Normalização de E-mails:** Conversão forçada para minúsculas (`lower()`), remoção de espaços em branco marginais e caracteres invisíveis de formatação (`strip()`). Múltiplos e-mails cadastrados em uma mesma célula foram segmentados por delimitadores (vírgulas, ponto-e-vírgula e barras).
- **Normalização Fonética e Nominal:** Remoção sistemática de acentuação gráfica (diacríticos) via conversão Unicode, eliminação de pontuações, conversão para caixa alta e descarte de partículas preposicionais de ligação (ex: "DE", "DA", "DO", "DOS", "DAS", "E").

> **Tratamento Metodológico dos Respondentes Anônimos do Survey**
>
> No Survey nacional (521 respondentes), 295 participantes exerceram o direito de sigilo, respondendo sem fornecer CPF, e-mail ou nome. Para evitar distorções estatísticas, a análise adotou **duplo denominador**: o percentual sobre a amostra com identificação nominal (N = 226) para aferição precisa da sobreposição física com os eventos, e o percentual sobre o universo total (N = 521) para mensuração da capilaridade da pesquisa.

4. Métodos Analíticos Utilizados e Como Foram Executados

4.1. Pareamento Determinístico Multinível (Entity Resolution) — Pergunta 1

Problema de Pesquisa: Determinar se os profissionais que responderam ao formulário de escuta nacional (survey) são os mesmos que participaram dos eventos nacionais de 2024.

Como foi feito: Implementou-se um algoritmo determinístico de resolução de entidades em três camadas hierárquicas e mutuamente excludentes, processado em memória vetorial:

```
Camada 1 (Chave Primária Forte): Casamento exato por CPF normalizado (11 dígitos). IF CPF_survey ≠ Nulo AND CPF_survey = CPF_evento THEN Match = True Camada 2 (Identificador Único Secundário): Casamento exato por E-mail limpo. IF Match = False AND Email_survey ≠ Nulo AND Email_survey = Email_evento THEN Match = True Camada 3 (Chave Quaternária Nominal): Casamento exato por Nome Normalizado. IF Match = False AND Nome_survey ≠ Nulo AND Nome_survey = Nome_evento THEN Match = True
```

Validação e Resultado: Dos 226 respondentes identificados, constatou-se que **166 pessoas (73,45%)** não possuíam qualquer registro nos eventos de 2024, comprovando que o survey capturou um contingente amplamente externo e inovador para as redes públicas.

4.2. Teoria dos Conjuntos e Métricas de Fluxo Longitudinal — Pergunta 2

Problema de Pesquisa: Verificar se a comunidade de eventos apresenta recorrência (fidelização do mesmo público) ou renovação contínua (atração de novos quadros).

Como foi feito: Aplicaram-se operações formais da teoria dos conjuntos sobre os conjuntos de inscritos únicos nos dois eventos consecutivos:

Definições de Conjuntos

- E_1: Conjunto de indivíduos únicos do Evento 1 ($|E_1| = 742$)
- E_2: Conjunto de indivíduos únicos do Evento 2 ($|E_2| = 386$)
- U: Comunidade consolidada única ($U = E_1 \cup E_2$, $|U| = 1.086$)
- S: Sobreposição física ($S = E_1 \cap E_2$, $|S| = 42$)
- N_2: Estreantes no Evento 2 ($N_2 = E_2 \setminus E_1$, $|N_2| = 344$)

Equações das Taxas

```
T_renov = (|N_2| / |E_2|) × 100 = 89,12%
T_rec_E2 = (|S| / |E_2|) × 100 = 10,88%
T_ret_E1 = (|S| / |E_1|) × 100 = 5,66%
T_rec_global = (|S| / |U|) × 100 = 3,87%
```

Interpretação Substantiva: O índice de renovação de quase 90% atesta que a mudança do foco temático de um evento para o outro mobilizou nichos distintos da administração pública, sem saturação da audiência.

4.3. Análise de Correspondência Múltipla (ACM) e Testes de Associação χ^2 — Pergunta 3

Problema de Pesquisa: Identificar a geometria estrutural entre o tempo de atuação profissional, o nível de titulação acadêmica e a função exercida no cotidiano.

Como foi feito:

1. **Testes de Independência Qui-Quadrado (χ^2):** Antes da redução dimensional, calculou-se a significância estatística da associação bivariada entre as variáveis mediante tabelas de contingência com o módulo `scipy.stats.chi2_contingency`:

   $$\chi^2 = \sum \left[(O_{ij} - E_{ij})^2 / E_{ij} \right] \quad \text{com} \quad E_{ij} = (R_i \times C_j) / N$$

   Onde O_{ij} é a contagem observada e E_{ij} é a frequência teórica esperada sob a hipótese nula (H_0). Constatou-se dependência altamente significante entre Titulação e Função ($\chi^2 = 70,06$; gl = 12; $p < 0,0001$) e entre Tempo e Titulação ($\chi^2 = 46,02$; gl = 16; $p = 0,0001$).
2. **Decomposição Fatorial da ACM:** Com o pacote `prince.MCA`, codificou-se a base de $N = 243$ observações em uma matriz indicadora disjuntiva completa Z ($N imes K$). Construiu-se a matriz de Burt $B = Z^T Z$. A decomposição em valores singulares (SVD) da matriz de correspondências padronizada extraiu as inércias principais:
   - **Fator 1 (Dimensão 1):** Autovalor explicando **15,07%** da inércia total. Opõe o Polo Acadêmico-Sênior (Doutores e Pesquisadores com >10 a 20 anos, com escores negativos -0,49 a -1,17) ao Polo Governamental-Operacional (Especialistas e Mestres com até 5 anos, escores positivos +0,69 a +1,11).
   - **Fator 2 (Dimensão 2):** Explicando **11,52%** da inércia, isola verticalmente as funções de Gerência/Coordenação (+2,75) em relação às funções de execução de pesquisa.

4.4. Mineração Espacial e Prevalência Setorial da Saúde — Pergunta 4

Problema de Pesquisa: Mapear a distribuição federativa das UFs, as esferas de atuação governamental e a inserção setorial da política pública.

Como foi feito:

- **Padronização Federativa:** Dicionário de sinônimos para conversão de siglas de UF e agregação nas 5 Grandes Regiões do IBGE (Norte, Nordeste, Centro-Oeste, Sudeste, Sul).
- **Classificação Setorial da Saúde:** Aplicação de expressões regulares sobre as colunas de "Órgão" e "Área Temática" para categorização binária (Saúde vs. Demais Políticas Públicas).
- **Tabulação Cruzada Multivariada (Esfera × Setor):** Cálculo das razões de prevalência setorial, revelando que a presença da Saúde atinge **67,4% no nível municipal** e **55,9% no nível estadual**, enquanto a União apresenta diversificação balanceada com Educação e Assistência Social.

4.5. Modelagem Não Supervisionada: Análise de Clusters (K-Means) — Pergunta 5

Problema de Pesquisa: Agrupar os profissionais segundo suas atribuições cotidianas, rotinas de trabalho e uso de metodologias no campo de M&A.

Como foi feito:

1. **Definição do Universo Amostral:** Filtragem exclusiva dos $N = 245$ respondentes do survey que declararam atuar diretamente com rotinas de M&A e evidências.
2. **Espaço Vetorial de Atributos (14 Dimensões Operacionais):** Construção de uma matriz de dados composta por 14 atributos padronizados cobrindo três eixos fundamentais:
   - *Eixo de Intensidade:* Atividade principal (binário 0/1), projetos ativos (0/1), atuação internacional (0/1) e tamanho da equipe de trabalho (variável contínua).
   - *Eixo de Ferramental Metodológico:* Uso habitual de estatística/econometria, métodos qualitativos, indicadores, sínteses de evidências, ATS, métodos participativos e questionários.
   - *Eixo de Impacto e Disseminação:* Comunicação orientada a tomadores de decisão (0/1), divulgação para a sociedade civil (0/1) e realização de capacitação contínua recente (0/1).
3. **Padronização Escalar Z-Score (StandardScaler):** Como a variável "tamanho da equipe" possui escala numérica contínua (1 a 50 pessoas) e as demais são variáveis binárias (0 ou 1), a aplicação direta da distância euclidiana causaria distorção artificial, fazendo com que o tamanho da equipe dominasse o algoritmo. Aplicou-se a padronização z-score em todas as 14 dimensões:

   $$z_i = (x_i - \mu_i) / \sigma_i$$

   Onde μ_i é a média aritmética e σ_i é o desvio-padrão amostral do atributo i.
4. **Parametrização do Algoritmo K-Means:**

```
from sklearn.cluster import KMeans from sklearn.preprocessing import StandardScaler scaler = StandardScaler() X_scaled = scaler.fit_transform(df_features) kmeans = KMeans( n_clusters=3, init='k-means++', # Inicialização inteligente para evitar mínimos locais n_init=20, # 20 execuções independentes com diferentes centroides max_iter=300, # Limite máximo de convergência tol=1e-4, # Tolerância relativa de parada random_state=42 # Garantia de reprodutibilidade estrita ) cluster_labels = kmeans.fit_predict(X_scaled)
```

5. **Caracterização das Centroides dos 3 Perfis Encontrados:**
   - **Cluster 1 (13,1% - 32 prof.):** *Especialistas em ATS e Síntese de Evidências em Grandes Equipes.* 100% aplicam Avaliação de Tecnologias em Saúde (ATS), 68,8% fazem síntese, atuam em equipes médias de 8,7 pessoas e apresentam 31,3% de internacionalização.
   - **Cluster 2 (37,1% - 91 prof.):** *Avaliadores Ocasionais / Prática Periférica.* Apenas 26,4% têm M&A como atividade principal, menor complexidade instrumental (apenas 19,8% usam estatística e 38,5% indicadores) e equipes reduzidas (4,4 pessoas).
   - **Cluster 3 (49,8% - 122 prof.):** *Núcleo Multimetodológico de Alta Intensidade.* 75,4% têm M&A como dedicação principal, 94,3% possuem projetos em andamento, dominam múltiplos métodos (78,7% indicadores, 72,1% surveys, 65,6% qualitativo, 63,9% estatística) e 90,2% dialogam ativamente com decisores de governo.

4.6. Cruzamentos Multivariados e Análise de Interseccionalidade (Insights Aplicados)

A partir da validação dos dados suplementares, realizaram-se tabulações cruzadas de alta relevância para a equidade e gestão pública:

- **Interseccionalidade de Gênero nos Clusters:** O teste revelou que a liderança feminina predomina em todas as vertentes, atingindo ápice no Cluster 1 de ATS e Síntese, onde **75,0% das especialistas são mulheres**.
- **Afunilamento Étnico-Racial:** Cruzando raça autodeclarada e titulação acadêmica, evidenciou-se que a proporção de pessoas brancas salta de 58% na graduação para **mais de 73% no doutorado e pós-doutorado**. No Cluster 3 (núcleo duro de maior prestígio e remuneração), **71,3% são brancos**, enquanto profissionais pardos concentram-se no Cluster 2 (34,1% - prática periférica).
- **Interiorização Federativa e Logística:** O cruzamento entre localidade e modalidade provou que, entre os participantes de fora do DF, **86,9% dependeram do formato Online** para ter acesso ao evento, demonstrando a centralidade da transmissão virtual.
- **O Abismo da Comunicação Pública:** Análise de frequências comparadas evidenciou que 73,5% dos avaliadores comunicam para governantes, mas apenas **33,1% divulgam para a sociedade civil** e público em geral, revelando uma barreira na popularização das evidências.

5. Engenharia de Artefatos, Diagramação e Publicação

Para garantir a difusão completa dos achados para múltiplos perfis de usuários (pesquisadores, tomadores de decisão e analistas de dados), o projeto gerou uma suíte integrada de 7 entregáveis construídos via automação:

ENTREGÁVEL GERADO	FORMATO	FERRAMENTA DE GERAÇÃO	PROPÓSITO E AUDIÊNCIA
Relatório Técnico Oficial	PDF (8 pág.)	Playwright Chromium + Matplotlib	Publicação oficial exaustiva contendo gráficos vetoriais, testes de hipóteses e diretrizes estratégicas.
Policy Brief Executivo	PDF (2 pág.)	Playwright Chromium	Documento ultracondensado formatado para leitura rápida por ministros, secretários e dirigentes públicos.
Manual da Planilha Consolidada	PDF (3 pág.)	Playwright Chromium	Dicionário formal de dados, regras de negócio e guia de navegação das 9 abas da planilha Excel.
Relatório de Metodologia e Ferramentas	PDF (6 pág.)	Playwright Chromium	Este documento, detalhando todas as tecnologias, equações matemáticas e algoritmos de análise.
Planilha Excel Consolidada	XLSX (9 abas)	pandas + openpyxl	Base analítica estilizada no padrão corporativo Navy (#0C182B), com autoajuste de largura e zebra striping.
Apresentação Executiva	PPTX (10 slides)	python-pptx	Slides em padrão widescreen 16:9 prontos para reuniões de diretoria, palestras e conferências.
Painel Analítico Web	HTML5 / SPA	Tailwind CSS + Chart.js v4	Aplicação interativa responsiva com 7 abas, filtros dinâmicos e gráficos em tempo real no navegador.

6. Reprodutibilidade, Auditoria e Governança no Git

Todo o código-fonte, bases de dados estruturadas e documentações técnicas encontram-se hospedados e versionados no repositório oficial do GitHub:

> **Repositório Oficial do Projeto**
>
> **URL Remota:** https://github.com/glau234/dados_ma_denise.git
> **Branch Padrão:** `main` | **Rastreamento:** Commits convencionais e sincronização automatizada

6.1. Como Reproduzir Toda a Análise a partir do Terminal

Qualquer pesquisador ou auditor pode reproduzir 100% dos resultados analíticos e gerar novamente todos os arquivos e PDFs executando a seguinte sequência de comandos no terminal:

```
# 1. Clonar o repositório git clone https://github.com/glau234/dados_ma_denise.git cd dados_ma_denise # 2. Instalar dependências científicas pip install pandas numpy scikit-learn prince scipy openpyxl python-pptx playwright matplotlib seaborn playwright install chromium # 3. Executar o pipeline analítico completo python generate_analysis.py # Mineração estatística, pareamento, ACM e K-Means → gera analise_dados_completa.json python build_excel_summary.py # Cria a planilha Excel consolidada de 9 abas (Relatorio_Tabelas_Consolidadas_MA_2024.xlsx) python generate_pdf_report.py # Gera o Relatório Oficial de 8 páginas (Relatorio_Completo_Monitoramento_Avaliacao_2024.pdf) python generate_policy_brief.py # Gera o Policy Brief de 2 páginas (Policy_Brief_Executivo_MA_2024.pdf) python generate_manual_pdf.py # Gera o Manual da Planilha em PDF (Manual_Estrutura_Planilha_Excel_MA_2024.pdf) python generate_methodology_pdf.py# Gera o Relatório de Metodologia em PDF python build_presentation.py # Gera os slides PowerPoint (Apresentacao_Executiva_Monitoramento_Avaliacao_2024.pptx) python build_html_dashboard.py # Atualiza o painel web interativo (painel_analise_evidencias.html)
```